

Trovare lo stato fondamentale con un circuito

Documento 2 — VQE, e perché la scelta dell'ansatz è il vero risultato

Samuele Schiavi

Tesi triennale in Fisica, Università di Parma — Relatore: Prof. Alessandro Chiesa

1 Come funziona, in pratica

Il Variational Quantum Eigensolver risolve un problema di minimo. Si costruisce un circuito quantistico che dipende da un insieme di angoli θ ; il circuito prepara uno stato $|\psi(\theta)\rangle$; si misura l'energia media $E(\theta) = \langle\psi(\theta)|H|\psi(\theta)\rangle$; un ottimizzatore classico aggiorna gli angoli per abbassarla. Il principio variazionale garantisce che $E(\theta) \geq E_0$ sempre: non si può scendere sotto il valore vero.



Figura 1: Il ciclo VQE. La macchina quantistica prepara e misura; l'ottimizzatore classico decide dove muoversi. L'unica cosa che il fisico sceglie è la struttura del circuito parametrico — ed è quella scelta a decidere se il metodo funziona.

Sul dimero l'energia esatta è nota, quindi il VQE non serve a scoprirla: serve a misurare quanto bene un dato circuito riesce a rappresentare lo stato giusto. La grandezza che useremo è la *fidelity* $\mathcal{F} = |\langle\psi_{\text{VQE}}|\psi_0\rangle|$, che vale 1 quando i due stati coincidono.

In una riga. Sul dimero il VQE è uno strumento diagnostico: mette alla prova l'ansatz, non l'Hamiltoniana.

2 Due filosofie di circuito

Ansatz generico (hardware-efficient)

Si impilano rotazioni a un qubit e porte di entanglement in uno schema regolare, senza guardare alla fisica del problema. Nel nostro caso: rotazioni R_y alternate a porte CZ , per un totale di 6 parametri.




Figura 2: L'ansatz generico. Nessuna informazione sul sistema è entrata nella sua costruzione: la stessa struttura si userebbe per qualunque Hamiltoniana a due qubit.

Ansatz fisicamente motivato

L'alternativa è costruire il circuito *a partire* da quel che si sa dello stato cercato. Sotto l'incrocio lo stato fondamentale è il singoletto, sopra è $|\uparrow\downarrow\rangle$: si prepara direttamente lo stato giusto e si aggiunge un blocco a due qubit con un angolo libero, che permette di deformarlo. Un parametro invece di sei.

Quel blocco è realizzato con due CNOT che racchiudono una rotazione $R_y(\theta)$ su un solo qubit:




Figura 3: Il blocco a un parametro usato nell'ansatz minimo: due CNOT, non due CZ, attorno a un'unica R_y . È una rotazione reale, confinata al sottospazio a due dimensioni generato dallo stato di preparazione (il singoletto sotto l'incrocio, $|\uparrow\downarrow\rangle$ sopra).




Figura 4: L'ansatz fisicamente motivato nella sua forma minima: preparazione esplicita del singoletto (le prime quattro porte) seguita dal blocco di Fig. 3. Il circuito incorpora ciò che sappiamo del problema, invece di lasciarlo scoprire all'ottimizzatore.

3 Il confronto, e dove si rompe




Figura 5: Fidelity rispetto allo stato fondamentale esatto, al variare del campo. **A sinistra**, senza termine DM: entrambi gli ansatz sono perfetti su tutto il range, e quello a un parametro fa lo stesso lavoro di quello a sei. **A destra**, con il DM acceso: l’ansatz generico resta perfetto, quello fisicamente motivato crolla a 0.70 proprio dove il DM conta di più.

Il pannello di sinistra è il risultato “positivo”: imporre la simmetria giusta riduce il costo di un fattore sei senza perdere nulla. È il messaggio centrale di Crippa et al. (*Magnetochemistry* **7**, 117, 2021), il riferimento metodologico del progetto.

Il pannello di destra è il risultato più istruttivo. L’ansatz fisicamente motivato fallisce, e fallisce in modo localizzato: lontano dall’incrocio va benissimo, nell’intorno di $B/J = 2$ perde un terzo della fidelity. La ragione non è che ha pochi parametri.

Un dettaglio che vale la pena rendere esplicito, perché a un primo sguardo il grafico sembra dire qualcosa di più forte di quello che dice davvero: il circuito non prepara *sempre* il singoletto. È costruito con due rami, scelti a seconda di B/J : sotto l’incrocio prepara il singoletto (che vive nel sottospazio $\{|01\rangle, |10\rangle\}$), sopra prepara $|\downarrow\downarrow\rangle$ (che vive nel sottospazio $\{|00\rangle, |11\rangle\}$). Il blocco a un parametro ruota *dentro* qualunque sottospazio sia partito, e non ne esce mai — lo si verifica applicandolo a entrambe le preparazioni per diversi valori dell’angolo: le ampiezze restano rigorosamente nulle sulle due componenti non raggiungibili da quel ramo, per ogni θ .




Figura 6: I due rami del circuito minimo, visti come due sottospazi disgiunti. Il singolo parametro θ ruota liberamente *dentro* il sottospazio di partenza, ma non può mai farlo uscire verso l’altro: sono due rette parallele, non un unico spazio esplorato per intero.

Quindi per $B/J > 2$ il circuito non sta più cercando (male) il singoletto: è nel settore giusto per costruzione. Ma «giusto» non vuol dire «esatto». Il termine DM accoppia $|00\rangle$ e $|11\rangle$ direttamente al settore $\{|01\rangle, |10\rangle\}$ (gli elementi di matrice di X_1Z_2 e Z_1X_2 lo mostrano

esplicitamente), quindi il vero stato fondamentale porta sempre un po' di quel settore con sé, anche lontano dall'incrocio — solo, sempre meno quanto più ci si allontana:

B/J	fidelity	$1 - \mathcal{F}$
0.00	0.995133	4.9×10^{-3}
1.80	0.890358	1.1×10^{-1}
1.99	0.725176	2.7×10^{-1}
2.00	0.700841	3.0×10^{-1}
2.05	0.760745	2.4×10^{-1}
2.50	0.966592	3.3×10^{-2}
4.00	0.997527	2.5×10^{-3}

Tabella 1: La fidelity dell'ansatz minimo, punto per punto. Lontano dall'incrocio è un'ottima approssimazione ($\mathcal{F} > 0.99$), non una corrispondenza esatta: sulla scala del grafico di Fig. 5 (che parte da 0.4) uno scarto dello 0.5% è semplicemente invisibile, e la curva sembra “tornare a 1” dove in realtà si avvicina soltanto. La stessa fisica del Documento 1 vista da un altro angolo: la mescolanza indotta dal DM è enorme esattamente dove i livelli imperturbati sono degeneri, e si affievolisce rapidamente allontanandosene.

Una domanda naturale a questo punto: la scelta del ramo (la condizione $B/J < 2$) è sempre quella giusta, cioè sceglie sempre il ramo che darebbe la fidelity migliore? Quasi sempre — ma non proprio esattamente:

B/J	fid(singoletto)	fid($ \downarrow\downarrow\rangle$)	ramo scelto dal codice
1.90	0.8206	0.5707	singoletto (il migliore)
1.99	0.7252	0.6881	singoletto (il migliore)
2.00	0.7129	0.7008	$ \downarrow\downarrow\rangle$ — non il migliore
2.01	0.7004	0.7134	$ \downarrow\downarrow\rangle$ (il migliore)
2.10	0.5832	0.8121	$ \downarrow\downarrow\rangle$ (il migliore)

Tabella 2: Cosa darebbe *ciascun* ramo se venisse forzato su tutto il range, confrontato con quale ramo la condizione $B/J < 2$ sceglie davvero. La scelta coincide quasi sempre con la migliore possibile fra le due — tranne esattamente al confine, $B/J = 2$, dove per un margine sottile sceglie quella peggiore (0.7008 invece di 0.7129): un artefatto dello spigolo del confronto “<”, non un errore concettuale. Il minimo mostrato in Fig. 5 è dunque quello davvero prodotto dal codice, non il minimo teoricamente raggiungibile da un selettore di ramo ottimale.

Il punto di fondo non cambia: nessuno dei due rami esplora mai l'altro *simultaneamente* (Fig. 6) — il circuito non calcola mai una sovrapposizione dei due, sceglie classicamente uno dei due prima ancora di girare l'unico angolo che possiede. È precisamente perché un solo parametro reale non può fare di meglio che serve una struttura diversa: la riparazione di Sez. 5, che segue, non aggiunge un secondo ramo più furbo — elimina la necessità di sceglierne uno.

4 Perché non è una questione di parametri

Con il DM acceso, lo stato fondamentale vicino all'incrocio è una miscela

$$|\psi_0\rangle = \alpha|\text{singoletto}\rangle + \beta|\downarrow\downarrow\rangle, \quad (1)$$

cioè una sovrapposizione di due stati con magnetizzazione diversa. L'ansatz fisicamente motivato, costruito con blocchi che conservano M , resta confinato in un settore: quello stato è fuori dalla sua portata, letteralmente irraggiungibile.

Il modo per dimostrarlo senza margine di dubbio è aggiungere parametri e vedere che non serve a nulla: ripetiamo K volte il blocco CNOT- R_y -CNOT di Fig. 3 (lo stesso già introdotto, non un gate nuovo), ciascuna copia con il proprio angolo indipendente, a partire dallo stesso ramo che il circuito sceglie a $B/J = 2$ (il ramo $|\downarrow\downarrow\rangle$: la condizione " $B/J < 2$ " è falsa esattamente nel punto di confine).

blocchi CNOT- R_y -CNOT	parametri	fidelity a $B/J = 2, D/J = 0.2$
1	1	0.700841
2	2	0.700841
3	3	0.700841
4	4	0.700841

Tabella 3: Il tetto strutturale. Quadruplicare i parametri non sposta la fidelity di una sola cifra decimale — e il valore coincide esattamente con quello di un solo blocco (il minimo di Fig. 5): l'ottimizzatore sta già facendo il meglio possibile dentro il settore in cui è confinato. Il limite non è la capacità espressiva del circuito, è la simmetria che gli abbiamo imposto. Ripetere lo stesso blocco confinato allo stesso sottospazio non aggiunge direzioni raggiungibili, qualunque sia K .

In una riga. Un ansatz che rispetta una simmetria dell'Hamiltoniana è enormemente più efficiente. Un ansatz che rispetta una simmetria che l'Hamiltoniana *non* ha è strutturalmente incapace, e nessun numero di parametri lo salva.

5 La riparazione

Prima di mostrare la cura, una parentesi necessaria: il blocco M -conservante che useremo da qui in avanti non è quello di Fig. 3, ma un altro, diverso — RBS. Vale la pena costruirlo con cura, vederne la matrice, e solo alla fine confrontarlo con l'alternativa di letteratura.

RBS: una rotazione di Givens

Applicando $\text{RBS}(\varphi)$ ai quattro stati della base computazionale si ottiene, per verifica diretta:

$$\text{RBS}(\varphi) = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & \cos \varphi & -\sin \varphi & 0 \\ 0 & \sin \varphi & \cos \varphi & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}, \quad \text{base } \{|00\rangle, |01\rangle, |10\rangle, |11\rangle\}. \quad (2)$$

Una matrice interamente *reale*, identità su $|00\rangle$ e $|11\rangle$, e una rotazione ordinaria 2×2 sul piano $\{|01\rangle, |10\rangle\}$. Questa è esattamente, per definizione, una **rotazione di Givens**: un operatore ortogonale che ruota un solo piano coordinato di uno spazio più grande, lasciando invariato tutto il resto. Non è un'analogia — è il nome proprio dell'oggetto.

La ragione per cui basta una rotazione di Givens, e non serve esplorare l'intero gruppo unitario $U(2)$ del settore $M = 0$, è il **teorema spettrale**: una matrice reale simmetrica come la nostra H ammette sempre una base di autovettori reali, qualunque sia la degenerazione. Lo stato fondamentale che l'ansatz deve raggiungere è reale; un operatore che deve portare uno stato reale in un altro stato reale, restando dentro un piano a due dimensioni, non ha bisogno di fasi complesse — gli basta ruotare, cioè gli basta essere una rotazione di Givens. RBS lo è per costruzione.




Figura 7: $RBS(\varphi)$ nelle sue porte elementari: due CZ attorno a una coppia di rotazioni $R_y(\varphi), R_y(-\varphi)$, sandwiched fra Hadamard. Due porte a due qubit in tutto.

L'alternativa di letteratura: $W_{ij}(\theta)$

In letteratura (Crippa et al.) il blocco M -conservante standard non è RBS: è

$$W_{ij}(\theta) = e^{-i\theta \mathbf{s}_i \cdot \mathbf{s}_j}, \quad \mathbf{s} = \boldsymbol{\sigma}/2. \quad (3)$$

Nella stessa base:

$$W_{ij}(\theta) = e^{i\theta/4} \begin{pmatrix} e^{-i\theta/2} & 0 & 0 & 0 \\ 0 & \cos(\theta/2) & -i \sin(\theta/2) & 0 \\ 0 & -i \sin(\theta/2) & \cos(\theta/2) & 0 \\ 0 & 0 & 0 & e^{-i\theta/2} \end{pmatrix}. \quad (4)$$

A meno della fase globale davanti, il blocco 2×2 centrale ha la stessa struttura $\cos, \sin$ di RBS ma con un fattore $-i$ davanti al seno: non è una rotazione reale, è nella famiglia iSWAP. $\mathbf{s}_i \cdot \mathbf{s}_j$ è diagonale nella base singoletto/tripletto, con autovalori $\frac{1}{4}$ (tripletto) e $-\frac{3}{4}$ (singoletto) — una fase relativa fra i due settori, non una rotazione.

$W_{ij}(\theta)$ ha anch'esso una realizzazione esatta in porte elementari: scrivendo $\mathbf{s}_i \cdot \mathbf{s}_j = \frac{1}{4}(X_i X_j + Y_i Y_j + Z_i Z_j)$ e usando che $X_i X_j, Y_i Y_j, Z_i Z_j$ commutano a due a due (lo stesso fatto già verificato per lo scambio isotropo H_1 nel Documento 3), l'esponenziale si fattorizza senza approssimazioni:

$$W_{ij}(\theta) = R_{xx}(\theta/2) R_{yy}(\theta/2) R_{zz}(\theta/2). \quad (5)$$

Sono esattamente le stesse porte usate per H_1 nel passo di Trotter — non per coincidenza: $\mathbf{s}_i \cdot \mathbf{s}_j$ e lo scambio isotropo sono la stessa struttura algebrica, solo con normalizzazioni diverse.




Figura 8: $W_{ij}(\theta)$ nelle sue porte elementari: R_{xx} , R_{yy} e una R_{zz} (disegnata da Qiskit con l’etichetta “ZZ”, simbolo nativo, non $\oplus$) in sequenza. Tre porte a due qubit — una più delle due di RBS.

Un chiarimento sui due disegni, perché Qiskit li rende visivamente simili: in Fig. 8 l’ultima porta è $R_{zz}(\theta/2) = e^{-i\theta/4} Z \otimes Z$, una *rotazione continua*; in Fig. 7 le due porte a due qubit sono $CZ = \text{diag}(1, 1, 1, -1)$, un gate *fisso*, senza parametro. Non sono lo stesso oggetto — ma sono imparentati: si verifica per moltiplicazione diretta che

$$i \cdot CZ = e^{i\pi/4} (R_z(-\pi/2) \otimes R_z(-\pi/2)) R_{zz}(\pi/2), \quad (6)$$

cioè CZ si ottiene da $R_{zz}(\pi/2)$ aggiungendo due rotazioni R_z locali e una fase globale: stessa capacità di generare entanglement (localmente equivalenti), ma matrici diverse. Il simbolo grafico che si assomiglia (due pallini uniti da una linea) è una parentela di famiglia nel disegno di Qiskit, non un’identità matematica fra le due porte.

Le **probabilità** $\cos^2 \varphi, \sin^2 \varphi$ di RBS e W (con $\theta = 2\varphi$) sono identiche: i due gate sono equivalenti a livello di popolazioni. A distinguerli è la fase relativa fra le due ampiezze — reale per RBS, immaginaria per W .

La fase in più di W costa, e non serve. Costa: la sua implementazione richiede 3 porte a due qubit contro le 2 di RBS, il 50% in più — un costo che pesa ancora di più quando studieremo il sistema come sistema aperto, dove ogni porta a due qubit è un canale di rumore aggiuntivo. Non serve: per lo stesso teorema spettrale invocato sopra, un ansatz che deve raggiungere solo stati reali non ha bisogno di esplorare l’intero $U(2)$ del settore $M = 0$: gli basta il sottogruppo reale $SO(2)$ che RBS già esplora per intero, in quanto rotazione di Givens. La fase extra di W è un grado di libertà sempre sprecato, per la stessa ragione matematica del tetto strutturale di Tab. 3 — lì il parametro extra era un angolo, qui è una fase per blocco, ma la conclusione è identica: aggiungere ciò che l’Hamiltoniana non richiede non aiuta.

In una riga. A parità di popolazioni, RBS costa meno di W e non perde nulla: la fase che W porta con sé è dimostrabilmente superflua per un’Hamiltoniana reale come la nostra — ed è per questo, in una parola, che RBS è una rotazione di Givens e W no.

La riparazione, con RBS

La diagnosi di prima suggerisce la cura: servono rotazioni che escano dal settore a M fissato. Aggiungendo al blocco RBS una coppia di rotazioni R_y indipendenti sui due qubit — due parametri in più, tre in totale — la fidelity torna a 1 ovunque.




Figura 9: L'ansatz esteso: il blocco RBS (Fig. 7, qui compattato in un'unica scatola) seguito da due rotazioni indipendenti. Sono queste due rotazioni a permettere allo stato di uscire dal settore, ed è per questo che due parametri in più fanno la differenza mentre tre blocchi M -conservanti identici in più (Tab. 3, con CNOT- R_y -CNOT, ma la conclusione vale per RBS altrettanto) non la facevano.




Figura 10: Con il DM acceso: l'ansatz a tre parametri raggiunge la fidelity massima su tutto il range, esattamente come quello generico a sei. Metà dei parametri, stesso risultato — e a differenza dell'ansatz generico, ogni parametro corrisponde a un'operazione di cui si sa dire il ruolo fisico.

— **Come lo sappiamo.** Tutti i punti delle figure provengono da ottimizzazioni indipendenti con 8 punti di partenza casuali ciascuna, per escludere che una curva bassa sia un minimo locale invece di un limite strutturale. La fidelity è calcolata come proiezione sul *sottospazio* fondamentale, non su un singolo autovettore:

$$\mathcal{F} = \sqrt{\sum_{k: E_k \approx E_0} |\langle v_k | \psi_{\text{ansatz}} \rangle|^2},$$

dove la somma corre su *tutti* gli autovettori v_k degeneri col fondamentale, non su uno solo: a $D = 0$ e $B/J = 2$ lo stato fondamentale è degenero, e confrontarsi con un autovettore arbitrario restituito dalla diagonalizzazione darebbe un numero privo di significato. Al punto di lavoro “test 2” ($b/J = 0.35$, $D/J = 0.80$) l’ansatz esteso dà un errore in energia di 4×10^{-13} e $\mathcal{F} = 1.000000000000$.

6 Che cosa si porta via da qui

Il risultato utilizzabile non è “il VQE funziona sul dimero” — lo si sapeva. È il criterio di progetto: **un ansatz va costruito sulle simmetrie che l’Hamiltoniana ha davvero, non su quelle che sarebbe comodo avesse.** Questo criterio è stato poi applicato tale e quale a $N = 3$, dove la verifica diretta è più costosa e conviene sapere in anticipo cosa cercare.

Resta un punto aperto, questa volta non sulla scelta del gate (chiarita in Sez. 5) ma sulla sua collocazione: se e come estendere questo stesso confronto RBS/ W quando l’ansatz verrà applicato a $N = 3$, dove il sottospazio a magnetizzazione fissata è più grande e la scelta del blocco potrebbe pesare di più sul conteggio totale dei gate.

Un’anticipazione: lo stesso confronto, al punto del Documento 3

Il Documento 3 sceglie un punto di lavoro diverso da quelli usati fin qui — $b/J = -0.18$, $D/J = 1$, con un termine DM cinque volte più forte del $D/J = 0.2$ di Fig. 5 — per ragioni che riguardano la dinamica temporale, non l’ottimizzazione. Vale la pena controllare se il confronto fra i tre ansatz di questo documento regge anche in quel punto, prima di darlo per scontato:

ansatz (nome nel testo)	etichetta nelle figure	fidelity a $b/J = -0.18$, $D/J = 1$
generico, hardware-efficient (Fig. 5)	HA (6 par.)	1.000000
fisicamente motivato, minimo (Fig. 5)	PMA base (1 par.)	0.922857
fisicamente motivato, esteso (Fig. 10)	PMA esteso (3 par.)	1.000000

Tabella 4: Lo stesso confronto delle Fig. 5 e 10, ricalcolato al punto di lavoro che userà il Documento 3. Anche con un DM cinque volte più forte la storia non cambia: l’ansatz minimo perde una fetta di fidelity non trascurabile, quello esteso resta indistinguibile dall’esatto ($\mathcal{F} = 1$ a dodici cifre). Questi numeri tornano nel Documento 3, dove ne segue direttamente la dinamica temporale.

Riferimento. Per le rotazioni di Givens (l’origine del nome, e il loro uso classico nell’algebra lineare numerica): W. Givens, *Computation of Plane Unitary Rotations Transforming a General Matrix to Triangular Form*, J. Soc. Indust. Appl. Math. **6**(1), 26–50 (1958); trattazione moderna in G. H. Golub, C. F. Van Loan, *Matrix Computations*, Johns Hopkins University Press, 4^a ed. (2013), §5.1.

Riferimento. Per la famiglia iSWAP (il gate e la sua origine dall’interazione XY fra due qubit): N. Schuch, J. Siewert, *Natural two-qubit gate for quantum computation using the XY interaction*, Phys. Rev. A **67**, 032301 (2003).

Riferimento. Per la fidelity, inclusa la sua estensione naturale a un sottospazio degenero (proiettare invece di confrontare con un singolo vettore): M. A. Nielsen, I. L. Chuang, *Quantum Computation and Quantum Information*, Cambridge University Press, ediz. del decimo anniversario (2010), cap. 9.